

Отчёт по типовику, функция $f(x, y) = 6xy - x^3 - y^3$

Выполнил: Быков Владимир(465327)

1 Постановка задачи

Рассматривается функция

$$f(x, y) = 6xy - x^3 - y^3.$$

Цели:

1. Аналитически найти стационарные точки и классифицировать их.
2. Построить графики поверхности и уровней, отметить стационарные точки.
3. Реализовать и протестировать алгоритмы: градиентный метод с постоянным шагом, с убывающим шагом (деление), метод наискорейшего спуска (точный одномерный поиск), методы Полака–Райбера и Флетчера–Ривса, а также сопряжённый градиент (FR, PR).
4. Сравнить аналитические решения с численными результатами и собрать статистику для $\varepsilon = 10^{-k}$, $k = 2..6$.

2 Аналитический этап

2.1 Нахождение стационарных точек

Стационарные точки определяются решением системы

$$\nabla f(x, y) = \begin{pmatrix} f_x \\ f_y \end{pmatrix} = \begin{pmatrix} 6y - 3x^2 \\ 6x - 3y^2 \end{pmatrix} = 0.$$

Решая систему получаем

$$2y - x^2 = 0, \quad 2x - y^2 = 0.$$

Из первой: $y = \frac{x^2}{2}$. Подставляя во вторую:

$$x = \frac{1}{2} \left(\frac{x^2}{2} \right)^2 = \frac{x^4}{8}.$$

Следовательно $x \left(\frac{x^3}{8} - 1 \right) = 0$, откуда реальные решения: $x = 0$ и $x = 2$. Соответственно $y = 0$ и $y = 2$. Итак, стационарные точки:

$$(0, 0), \quad (2, 2).$$

2.2 Матрица Гессе и проверка достаточного условия экстремума

Вычислим вторые производные:

$$f_{xx} = -6x, \quad f_{yy} = -6y, \quad f_{xy} = f_{yx} = 6.$$

Матрица Гессе:

$$H(x, y) = \begin{pmatrix} -6x & 6 \\ 6 & -6y \end{pmatrix}.$$

Точка $(0, 0)$

$$H(0, 0) = \begin{pmatrix} 0 & 6 \\ 6 & 0 \end{pmatrix}.$$

Её определитель $\det H(0, 0) = -36 < 0$, следовательно матрица не положительно/отрицательно определена — это седловая точка (не экстремум).

Точка $(2, 2)$

$$H(2, 2) = \begin{pmatrix} -12 & 6 \\ 6 & -12 \end{pmatrix}.$$

Трасса $\text{tr} = -24$, детерминант $\det = (-12)^2 - 6^2 = 108 > 0$, собственные значения $\lambda_{1,2} = \frac{-24 \pm 12}{2} = -6, -18$, оба отрицательны. Следовательно $H(2, 2)$ отрицательно определена, и $(2, 2)$ — точный локальный максимум. Значение функции в точке: $f(2, 2) = 6 \cdot 2 \cdot 2 - 8 - 8 = 8$.

2.3 Проверка по определению (для седловой точки)

Для $(0, 0)$ можно показать наличие направлений с возрастанием и убыванием функции: вдоль прямой $y = x$ имеем

$$f(x, x) = 6x^2 - 2x^3 = 2x^2(3 - x),$$

для малых положительных x выражение положительно, а вдоль направления $y = -x$:

$$f(x, -x) = -6x^2 + 0 - 2x^3 = -6x^2 - 2x^3 < 0$$

(для малых $x \neq 0$). Следовательно $(0, 0)$ — седловая точка.

3 Практическая часть

В практическом этапе рассматриваются численные методы оптимизации и сложные моменты их реализации.

3.1 Основные методы

Реализованы следующие методы:

- Градиентный спуск с постоянным шагом α .
- Градиентный спуск с убывающим шагом.
- Метод наискорейшего спуска (точный одномерный поиск шага).
- Сопряжённый градиент (FR и PR).

3.2 Основной алгоритм градиентного спуска

Ниже приведён сокращённый пример основной логики метода градиентного спуска. В отчёте важны пояснения, а не полный код визуализации.

Listing 1: Основной алгоритм градиентного спуска

```
def gradient_descent(f, grad_f, x0, y0, alpha_rule, eps=1e-6, max_iter=100):
    x, y = x0, y0
    history = [(x, y, f(x,y))]
    for k in range(max_iter):
        gx, gy = grad_f(x, y)
        alpha = alpha_rule(x, y, gx, gy, k)
        x -= alpha * gx
        y -= alpha * gy
        history.append((x, y, f(x,y)))
        if np.linalg.norm([gx, gy]) < eps:
            break
    return x, y, history
```

3.3 Сложные моменты и пояснения

- **Выбор шага α_k :** от него сильно зависит сходимость. Постоянный шаг прост, но может быть слишком большим или малым. Убывающий шаг уменьшает риск расходимости, но замедляет метод. Метод наискорейшего спуска обеспечивает максимальное уменьшение функции за один шаг, но требует одномерного поиска.
- **Сохранение истории итераций:** важно для анализа траектории, числа итераций и визуализации. В отчёте достаточно описать, что каждая точка сохраняется вместе со значением функции.
- **Сложные функции:** для функций с несколькими локальными экстремумами (Rosenbrock, Rastrigin, Eggholder) градиентные методы могут застревать в локальных минимумах. В отчёте необходимо пояснить эти особенности и влияние начальной точки на сходимость.
- **Сопряжённый градиент:** улучшает сходимость на квадратичных функциях, уменьшает колебания в узких канавках. Для сложных функций важно подобрать критерий останова и вычисление коэффициента β (FR или PR).
- **Критерии останова:** обычно используется норма градиента или изменение значения функции меньше ε .

3.4 Сопряжённый градиент (Conjugate Gradient)

Сопряжённый градиент — это метод ускоренного спуска, особенно эффективный для квадратичных функций или узких канавок. Основные моменты:

- **Направление спуска:** вычисляется через текущий градиент и предыдущее направление с использованием коэффициента β (варианты FR и PR).
- **Выбор шага:** одномерный поиск вдоль направления d_k , например, backtracking или золотое сечение.

- **Обновление направления:** $d_{k+1} = -\nabla f_{k+1} + \beta_k d_k$, где β_k определяется вариантом FR или PR.
- **Критерий остановки:** норма градиента меньше ε .
- **Особые моменты:** алгоритм может использовать численный градиент, если аналитический не предоставлен.

Алгоритм Conjugate Gradient

1. **Инициализация:** x_0, y_0 , вычисляем градиент $\nabla f(x_0, y_0)$
2. Задаём начальное направление: $d_0 = -\nabla f(x_0, y_0)$
3. Для $k = 0 \dots \text{max_iter}$:
 - (a) Проверяем: $\|\nabla f_k\| < \varepsilon$ — выход из цикла
 - (b) Выбираем шаг α_k (backtracking или line search)
 - (c) Обновляем точку: $x_{k+1} = x_k + \alpha_k d_k$
 - (d) Вычисляем новый градиент: ∇f_{k+1}
 - (e) Вычисляем коэффициент β_k (вариант FR или PR)
 - (f) Обновляем направление: $d_{k+1} = -\nabla f_{k+1} + \beta_k d_k$
4. Сохраняем историю итераций
5. Возвращаем: $x, y, \text{history}$

Градиентный спуск с постоянным шагом α

- Направление движения всегда совпадает с антиградиентом функции:

$$(x_{k+1}, y_{k+1}) = (x_k, y_k) - \alpha \nabla f(x_k, y_k)$$

- Шаг α фиксирован на протяжении всей итерации.
- Если α слишком велик — возможны колебания и расходимость метода.
- Если α слишком мал — метод сходится медленно, но стабильно.
- Подходит для гладких функций без резких перепадов.

Градиентный спуск с убывающим шагом

- Шаг α_k уменьшается с каждой итерацией:

$$\alpha_k = \frac{\alpha_0}{k+1}$$

или по другой убывающей формуле.

- Позволяет снизить риск расходимости при больших начальных шагах.
- Метод медленнее сходится на плоских участках, но стабильнее на крутых склонах.
- Используется, когда невозможно подобрать оптимальный постоянный шаг.

Метод наискорейшего спуска (точный одномерный поиск)

- На каждом шаге выбирается оптимальный α_k , минимизирующий функцию вдоль направления антиградиента:

$$\alpha_k = \arg \min_{\alpha} f((x_k, y_k) - \alpha \nabla f(x_k, y_k))$$

- Метод быстрее достигает экстремума по сравнению с фиксированным шагом.
- Может колебаться на узких канавках или сильно наклонных участках.
- Требуется одномерного поиска (например, методом золотого сечения).

Сопряжённый градиент (FR и PR)

- Направление спуска:

$$d_{k+1} = -\nabla f_{k+1} + \beta_k d_k$$

где β_k вычисляется по формулам Флетчера–Ривса (FR) или Полака–Райбера (PR).

- Шаг α_k выбирается одномерным поиском вдоль d_k .
- Метод особенно эффективен для квадратичных функций и узких канавок.
- Обеспечивает ускоренную сходимость и уменьшение колебаний по сравнению с обычным градиентным спуском.
- Критерий остановки: $\|\nabla f\| < \varepsilon$ или малое изменение значения функции.

3.5 Тестирование методов

- несмотря на то, что я формально сделал правильный градспуск, к 8 он не сошелся тк он не подходит для моей функции (ну или я не смог подобрать гиперпараметры тк на проверке все улетает в минимум на заданной области определения) так что он упираться яв лимит итераций и не сходясь к истинному минимуму
- Особенности траектории методов оптимизации

1. Градиентный спуск с постоянным шагом

- Направление движения всегда совпадает с антиградиентом функции.
- Если шаг α выбран слишком большим, метод может **колебаться** вокруг экстремума и замедлять сходимость.
- Если шаг слишком мал, метод сходится медленно, но стабильно.
- Траектория обычно выглядит как последовательность равномерных шагов, с возможными “зигзагами” при сильном наклоне поверхности.

2. Градиентный спуск с backtracking

- Шаг α_k выбирается автоматически через уменьшение до удовлетворения условия достаточного уменьшения функции.
- Обеспечивает **устойчивость метода**, снижает риск расходимости при крутых склонах.

- Траектория чаще плавная, шаги уменьшаются по мере приближения к экстремуму.

3. Метод наискорейшего спуска (точный одномерный поиск)

- Для каждого шага находится оптимальный α_k , минимизирующий функцию вдоль направления антиградиента.
- Метод быстро достигает локального экстремума на одномерной линии, но может **колебаться** при узких канавках или сильно наклонной поверхности.
- Траектория часто более прямолинейная, чем у простого градиентного спуска.

4. Сопряжённый градиент (FR и PR)

- Использует предыдущие направления для ускорения движения в нужном направлении.
- Особенно эффективен для узких канавок и квадратичных областей, где обычный градиентный спуск замедляется.
- Траектория обычно более **плавная**, с меньшими колебаниями, и быстрее достигает экстремума.

- Особенности траектории для сложных тестовых функций

– Розенброк, Растрингин, Eggholder

- * Эти функции имеют несколько локальных минимумов, что может приводить к застреванию методов градиентного спуска в локальных точках.
- * Имеют узкие канавки и крутые участки поверхности, что замедляет продвижение метода и требует аккуратного выбора шага.
- * На траекториях наблюдаются характерные изгибы и повороты, отражающие необходимость адаптивного шага или использования методов с ускорением (напр., сопряжённого градиента или наискорейшего спуска).
- * Для эффективного поиска глобального минимума рекомендуется анализировать поведение нескольких начальных точек и использовать устойчивые правила выбора шага, такие как backtracking.

3.6 Выводы практической части

Практическая часть показывает:

- Градиентные методы различаются по скорости и устойчивости.
- Сложные функции требуют аккуратного выбора начальной точки и шага.
- Сопряжённые градиенты и методы наискорейшего спуска эффективнее для узких канавок и сильно наклонных областей.
- Сохранение истории итераций позволяет анализировать траектории и сравнивать методы без построения графиков в отчёте.